

Classification de Radiographies Pulmonaires

Projet I.A. : Modélisation Machine Learning & Deep Learning

ABBOUCHI Houssein

CROCHAT Romuald

L'HOMMELET Mathilde

MOGHADDAM Sareh

1. Introduction et contexte du projet.....	4
2. Exploration des données.....	6
2.1 Structure et organisation du dataset.....	6
2.2 Vérification du format des images.....	7
2.3 Analyse des histogrammes de niveaux de gris.....	7
2.4 Étude de la luminosité par catégorie.....	9
2.5 Identification des outliers.....	10
2.6 Test statistique t de Student.....	12
3. Preprocessing.....	13
3.1 Stratégie de traitement des outliers.....	13
3.2 Égalisation d'histogramme globale.....	14
3.3 CLAHE : égalisation adaptative.....	14
3.4 Masques de segmentation pulmonaire.....	15
3.5 Impact des masques sur les histogrammes.....	16
3.6 Comparaison quantitative des 4 approches.....	18
4. Conclusion Partie 1 et pipeline retenu.....	20
5. Stratégie de modélisation	21
6. Rappel du pipeline de preprocessing.....	23
7. Extraction de caractéristiques.....	23
7.1 Pixels aplatis et réduction PCA.....	23
7.2 Descripteurs HOG (Histogram of Oriented Gradients).....	24
8. Modèles de classification.....	25
8.1 Régression Logistique.....	25
8.2 Random Forest.....	25
8.3 K-Nearest Neighbors (KNN).....	26
8.4 Support Vector Classifier SVC (SVM).....	26
8.5 Gradient Boosting (HistGradientBoosting).....	27
8.6 XGBoost.....	27
9. Synthèse comparative.....	28
9.1 Tableau récapitulatif.....	28
9.2 Analyse par classe : le problème COVID.....	28
9.3 Impact de la résolution d'image.....	30
10. Conclusion et prochaines étapes.....	30
11. Objectif de la phase Deep Learning.....	33
12. Pipeline expérimental commun.....	33
12.1 Jeu de données.....	33
12.2 Prétraitement des données.....	34
12.3 Gestion du déséquilibre des classes.....	34
12.4 Métriques d'évaluation.....	35
13. Étude des architectures évaluées.....	35
13.1 Réseau Dense : modèle de référence.....	35
13.2 CNN personnalisé.....	36
13.3 DenseNet121.....	37
13.4 EfficientNetB0.....	37

13.5 ResNet50.....	38
13.6 VGG16.....	38
14. Comparaison des architectures étudiées.....	39
14.1. Modèle Dense : point de départ.....	39
14.2. CNN personnalisé.....	40
14.3. Architectures de transfert d'apprentissage.....	40
14.4 Résultats comparatifs.....	40
15. Influence du CLAHE et de la Data Augmentation.....	41
Objectif.....	41
15.1. CNN custom.....	41
15.2. EfficientNetB0.....	41
15.3. DenseNet121.....	42
15.4. ResNet50.....	42
15.5. VGG16.....	42
15.6. Synthèse des effets.....	43
16. Choix du modèle final.....	44
16.1. Critères de choix.....	44
16.1.1. Performances quantitatives du modèle retenu.....	45
16.1.2. Compromis entre recall COVID et Macro-F1.....	46
16.1.3. La stabilité de l'apprentissage.....	46
16.1.4. La capacité de prédictions.....	47
16.2. Choix retenu.....	50
Scénario A : performance multiclass globale.....	50
Scénario B : priorité à la détection du COVID.....	50
17. Interprétabilité des prédictions.....	50
18. Analyse des erreurs.....	53
19. Discussion et limites.....	54
20. Conclusion.....	55
21. ANNEXES.....	56
GitHub Repository.....	56
Résultats Consolidés Complets.....	56
Analyse ROC et AUC.....	57
Références.....	59

1. Introduction et contexte du projet

L'interprétation des radiographies thoraciques constitue un élément essentiel du diagnostic de nombreuses pathologies pulmonaires. Parmi celles-ci, la pandémie de COVID-19 a mis en évidence l'intérêt de disposer d'outils d'aide à la décision capables d'assister les radiologues dans l'identification rapide des atteintes pulmonaires associées à l'infection.

Les progrès récents de l'intelligence artificielle, et plus particulièrement du Machine Learning et du Deep Learning, ont démontré leur capacité à extraire automatiquement des caractéristiques discriminantes à partir d'images médicales complexes. Toutefois, la performance de ces approches dépend fortement de la qualité des données, du prétraitement appliqué ainsi que du choix de l'architecture de classification.

Dans ce contexte, l'objectif de ce projet est de développer et d'évaluer un pipeline complet de classification automatique de radiographies thoraciques à partir du dataset COVID-19 Radiography Database. Le problème étudié consiste à prédire l'appartenance d'une radiographie à l'une des quatre catégories suivantes :

- * COVID-19
- * Normal
- * Lung Opacity
- * Viral Pneumonia

La démarche adoptée suit une logique expérimentale progressive. Une première phase est consacrée à l'exploration approfondie des données et à l'étude de différentes stratégies de prétraitement.

Une seconde phase vise à évaluer plusieurs modèles de Machine Learning classiques fondés sur des représentations manuelles des images.

Enfin, une troisième phase compare différentes architectures de Deep Learning afin d'identifier la solution la plus performante pour la détection des pathologies pulmonaires, avec une attention particulière portée à la classe COVID-19.

Au-delà de la recherche de performances prédictives élevées, ce travail s'intéresse également aux problématiques de robustesse, d'interprétabilité et de généralisation, qui constituent des enjeux majeurs pour toute application d'intelligence artificielle en santé.

La question de recherche centrale peut ainsi être formulée de la manière suivante :

Dans quelle mesure les techniques modernes de Machine Learning et de Deep Learning permettent-elles d'identifier de manière fiable les atteintes pulmonaires liées à la COVID-19 à partir de radiographies thoraciques, tout en conservant un niveau de généralisation compatible avec les exigences du domaine médical ?

Partie I : Exploration des données

Partie 1 — Exploration des données et prétraitement

Dataset : COVID-19 Radiography Database

21 165 radiographies • 4 catégories diagnostiques

2. Exploration des données

2.1 Structure et organisation du dataset

La première étape consiste à cartographier le dataset pour comprendre son organisation. Le jeu de données est téléchargé depuis Kaggle via l'API kagglehub, puis exploré récursivement :

Chargement et exploration du dataset

Structure découverte : Le dataset contient **21 165 radiographies** organisées en 4 catégories. Chaque catégorie dispose de deux sous-dossiers : ``images/`` (radiographies) et ``masks/`` (masques de segmentation pulmonaire pré-calculés).

Répartition des classes :

- **Normal** : 10 192 images (48,2%) — classe largement majoritaire
- **Lung_Opacity** : 6 012 images (28,4%)
- **COVID** : 3 616 images (17,1%)
- **Viral Pneumonia** : 1 345 images (6,4%) — classe minoritaire




Figure 1 : Exemples de radiographies par catégorie diagnostique

Réflexion : Le déséquilibre des classes est significatif — la classe "Normal" est 7,5 fois plus représentée que "Viral Pneumonia". Ce déséquilibre risque de biaiser l'apprentissage vers la classe majoritaire. Il devra être traité lors de la modélisation par sous-échantillonnage, augmentation de données, ou pondération des classes.

2.2 Vérification du format des images

Avant tout traitement, il est essentiel de vérifier l'homogénéité des images. Une vérification systématique est effectuée sur l'ensemble du dataset :

Vérification format et dimensions

Résultats de la vérification :

- **99,3%** des images sont en niveaux de gris (mode "L" de PIL)
- Les **0,7% restants** (140 images de "Viral Pneumonia") sont en couleur RGB
- **Toutes les images** ont la même dimension : **299×299 pixels**

Réflexion : L'uniformité des dimensions est un atout majeur qui simplifie considérablement le pipeline. Aucun redimensionnement n'est nécessaire, ce qui préserve la qualité des images. Les images en couleur seront simplement converties en niveaux de gris lors du chargement.

2.3 Analyse des histogrammes de niveaux de gris

L'**histogramme des niveaux de gris** est une représentation fondamentale en traitement d'images médicales. Il montre la distribution des intensités de pixels (0 = noir, 255 = blanc) et permet de caractériser le contraste, la luminosité et la dynamique d'une image.

Pour chaque catégorie, nous calculons l'histogramme agrégé de toutes les images afin de visualiser les profils de distribution caractéristiques :

Calcul des histogrammes par catégorie




Figure 3 : Densité lissée des niveaux de gris par catégorie + global

Analyse des histogrammes :

- Toutes les catégories présentent une **distribution bimodale** caractéristique des radiographies thoraciques : un premier pic vers les valeurs sombres (fond, médiastin) et un second pic vers les valeurs moyennes/clair (parenchyme pulmonaire).
- Les courbes sont globalement **similaires entre catégories**, ce qui suggère que les protocoles d'acquisition sont relativement homogènes.
- On observe cependant des **décalages subtils** : les images COVID semblent légèrement décalées vers les valeurs plus claires.

Pour mieux comprendre ces distributions, examinons des exemples individuels avec leurs histogrammes :




Figure 4 : Exemples d'images par catégorie avec leurs histogrammes individuels

Observation clé : Les histogrammes individuels révèlent une **grande variabilité** au sein de chaque catégorie. Certaines images présentent un histogramme très concentré (faible dynamique), d'autres très étalé. Cette variabilité provient des différences de protocoles d'acquisition entre les sources de données.

2.4 Étude de la luminosité par catégorie

Au-delà des histogrammes bruts, nous calculons trois métriques statistiques pour chaque image :

- **Luminosité moyenne** : intensité moyenne des pixels (indique si l'image est globalement sombre ou claire)
- **Écart-type** : mesure de la dispersion des intensités (indique le contraste)
- **Luminosité maximale** : valeur du pixel le plus clair (indique la saturation)

Extraction des métriques de luminosité




Figure 5 : Distribution KDE de la luminosité moyenne, écart-type et maximum




Figure 6 : Boxplots des métriques de luminosité par catégorie

Analyse des distributions :

- **Luminosité moyenne** : Les images COVID ont une moyenne légèrement plus élevée (139,5) que les autres catégories (125-129). Cette différence, bien que subtile, est statistiquement significative.
- **Écart-type** : Les 4 catégories ont des distributions de contraste similaires, centrées autour de 55-60.
- **Luminosité maximale** : La plupart des images atteignent des valeurs proches de 255 (saturation), avec quelques exceptions notables (valeurs < 200).

2.5 Identification des outliers

Les boxplots révèlent la présence de nombreux **points aberrants** (outliers) — des images dont la luminosité moyenne s'écarte significativement de la distribution principale. Ces outliers correspondent à des images très sombres ou très claires qui pourraient perturber l'apprentissage.

Pour les identifier systématiquement, nous définissons de manière heuristique des **seuils empiriques** basés sur l'observation des distributions :

- **Outlier sombre** : luminosité moyenne < 75
- **Outlier clair** : luminosité moyenne > 175




Figure 7 : Visualisation 3D des métriques (Mean/Std/Min) avec outliers en rouge

Exemples d'outliers sombres (mean < 75) :




Figure 8 : Exemples d'outliers sombres — images sous-exposées

Exemples d'outliers clairs (mean > 175) :




Figure 9 : Exemples d'outliers clairs — images sur-exposées

Réflexion critique : Ces images ne sont pas nécessairement "mauvaises" ou à supprimer. Elles contiennent potentiellement des informations diagnostiques valides, mais souffrent d'un problème d'exposition lors de l'acquisition. La stratégie retenue sera donc de tenter une

correction de contraste plutôt qu'une exclusion systématique.

2.6 Test statistique t de Student

Pour valider statistiquement l'hypothèse que les images COVID présentent des caractéristiques distinctes des images normales, nous réalisons un **test t de Student** (variante de Welch pour variances inégales) sur les intensités moyennes :

Test t de Student COVID vs Normal

Résultats :

- COVID : moyenne = **141,48**, écart-type = 20,70 (n=50)
- Normal : moyenne = **129,52**, écart-type = 27,27 (n=50)
- **T-statistic = 2,45, p-value = 0,0163**

Interprétation : Avec une p-value < 0,05, nous rejetons l'hypothèse nulle H_0 (pas de différence). Il existe une **différence statistiquement significative** entre les intensités moyennes des images COVID et Normal. La différence ($\Delta \approx 12$ unités de gris) indique que les radiographies COVID sont en moyenne légèrement plus claires.

Nuance importante : Cette différence statistique ne garantit pas une classification parfaite. Elle suggère simplement qu'un modèle pourrait exploiter cette caractéristique parmi d'autres. Le contraste local, les patterns de texture et les structures anatomiques restent les critères discriminants principaux.

3. Preprocessing

Fort des observations de la phase exploratoire, le preprocessing vise trois objectifs complémentaires :

1. **Corriger les anomalies de contraste** des outliers sans les supprimer
2. **Homogénéiser les distributions** intra-classe pour faciliter l'apprentissage
3. **Focaliser l'analyse** sur les régions anatomiquement pertinentes (poumons)

3.1 Stratégie de traitement des outliers

La première question est : que faire des outliers identifiés ? Deux approches sont envisageables :

- **Suppression** : Exclure les images aberrantes du dataset → Perte d'information potentiellement diagnostique
- **Correction** : Tenter de ramener les images dans une plage d'intensité normale → Conservation de l'information

La stratégie retenue est la **correction par égalisation d'histogramme**. L'idée est de redistribuer les intensités de pixels pour exploiter toute la dynamique [0-255], ce qui devrait améliorer le contraste des images sous/sur-exposées.

Détection des outliers




Figure 10 : Distribution des intensités avec seuils de détection des outliers

3.2 Égalisation d'histogramme globale

La fonction `cv2.equalizeHist()` d'OpenCV applique une égalisation globale : elle calcule la fonction de répartition cumulative (CDF) de l'histogramme et l'utilise comme fonction de transformation pour redistribuer les intensités.

Égalisation d'histogramme globale




Figure 11 : 15 outliers avant/après égalisation globale (equalizeHist)

Observation : L'égalisation globale améliore significativement le contraste des images sombres, mais a tendance à **sur-corriger** les images claires, créant parfois des artefacts de saturation. Une approche plus fine est nécessaire.

3.3 CLAHE : égalisation adaptative

CLAHE (Contrast Limited Adaptive Histogram Equalization) est une version améliorée de l'égalisation qui travaille de manière **locale** : l'image est divisée en tuiles, et l'égalisation est appliquée à chaque tuile indépendamment. Un paramètre `clipLimit` limite l'amplification du contraste pour éviter le bruit.

Application de CLAHE

Avantages de CLAHE par rapport à l'égalisation globale :

- Préserve les détails locaux (structures pulmonaires fines)
- Évite la sur-saturation des zones claires
- Contrôle fin via le paramètre `clipLimit`




Figure 12 : Comparaison Original vs EqualizeHist vs CLAHE sur 15 outliers

Analyse visuelle : CLAHE produit des résultats plus naturels que l'égalisation globale. Les structures anatomiques sont mieux préservées, et le contraste est rehaussé de manière équilibrée sur l'ensemble de l'image.

3.4 Masques de segmentation pulmonaire

Le dataset fournit des **masques de segmentation** pré-calculés pour chaque radiographie. Ces masques binaires délimitent la zone des poumons et permettent d'isoler la région d'intérêt anatomique.

Intérêt des masques :

- Éliminer les zones non pertinentes : clavicules, cœur, diaphragme, annotations textuelles
- Focaliser l'analyse sur les seuls tissus pulmonaires
- Réduire le bruit lié aux variations de positionnement du patient

Application des masques pulmonaires

L'application du masque pulmonaire agit comme une réduction de bruit en supprimant les régions non diagnostiques.




Figure 13 : Comparaison masques fournis vs masques automatiques simples

Observation : Les masques fournis dans le dataset sont de bonne qualité et délimitent précisément les contours pulmonaires. Les masques automatiques simples (par seuillage) sont moins précis et peuvent inclure des artefacts.

3.5 Impact des masques sur les histogrammes

L'application du masque modifie fondamentalement l'histogramme de l'image. En ne conservant que les pixels de la zone pulmonaire, on élimine les contributions du fond (pixels très sombres) et des structures osseuses (pixels très clairs).




Figure 14 : Image originale vs masquée avec comparaison des histogrammes




Figure 15 : Autre exemple de l'effet du masque sur la distribution des intensités

Analyse des histogrammes :

- L'histogramme **"Full image"** (bleu) présente des contributions aux deux extrémités : pixels sombres du fond et pixels clairs des os.
- L'histogramme **"Poumons seuls"** (orange) est plus concentré autour des valeurs moyennes, correspondant aux tissus pulmonaires.
- Le masquage **élimine le bruit** provenant des zones non diagnostiques et produit une distribution plus caractéristique de l'état des poumons.

3.6 Comparaison quantitative des 4 approches

Toutes les images sont finalement normalisées dans l'intervalle 0-1 afin de stabiliser l'apprentissage des modèles.

Pour déterminer le pipeline optimal, nous comparons systématiquement **4 configurations** de preprocessing sur un échantillon de 800 images (200 par classe) :

1. **Baseline** : Image brute normalisée [0-1], sans correction
2. **CLAHE** : Correction de contraste adaptative seule
3. **Masque** : Application du masque pulmonaire seul
4. **CLAHE + Masque** : Combinaison des deux techniques




Figure 16 : Comparaison visuelle des 4 approches avec histogrammes (exemple 1)




Figure 17 : Comparaison visuelle des 4 approches avec histogrammes (exemple 2)

Métriques d'évaluation :

- **Variance intra-classe** : Mesure l'homogénéité au sein de chaque catégorie (plus faible = mieux)
- **Écart-type inter-classe** : Mesure la séparation entre les moyennes de chaque catégorie
- **Test t COVID vs Normal** : Évalue la significativité statistique de la différence

Évaluation comparative des approches

Résultats quantitatifs :

	Approche	Variance intra	Std inter	p-value (t-test)
	Baseline	0.0077	0.032	9.3×10^{-7}
	CLAHE	0.0042	0.024	2.2×10^{-8}
	Masque	0.0091	0.035	1.6×10^{-12}
	CLAHE + Masque	0.0041	0.029	5.6×10^{-14}

Analyse des résultats :

- **CLAHE + Masque** obtient la **variance intra-classe la plus faible** (0.0041), indiquant la meilleure homogénéité au sein de chaque catégorie.
- Cette configuration produit également la **p-value la plus significative** (5.6×10^{-14}) pour le test COVID vs Normal, soit une séparabilité maximale.
- Le masque seul augmente légèrement la variance (car il supprime des pixels "moyennants"), mais combiné à CLAHE, l'effet est synergique.

- CLAHE seul réduit déjà fortement la variance par rapport à la baseline, confirmant l'intérêt de la correction de contraste.

4. Conclusion Partie 1 et pipeline retenu

L'analyse exploratoire approfondie et les tests comparatifs de preprocessing permettent de définir un **pipeline optimal** pour la préparation des radiographies avant modélisation.

PIPELINE DE PREPROCESSING RETENU

1. Chargement de l'image en niveaux de gris (conversion si nécessaire)
2. Application de CLAHE (clipLimit=2.0, tileGridSize=8×8)
3. Chargement et application du masque pulmonaire correspondant
4. Normalisation des valeurs dans l'intervalle [0, 1]
5. Augmentation de données pour les classes minoritaires et sous-échantillonnages de classe majoritaire

Synthèse de la démarche et réflexions clés :

- **Ne pas supprimer les outliers a priori** : La correction par CLAHE permet de récupérer des images exploitables qui auraient été perdues par une approche d'exclusion systématique. Ces images, bien que mal exposées, contiennent potentiellement des informations diagnostiques précieuses.
- **Combiner rehaussement de contraste et segmentation** : L'approche hybride CLAHE + Masque a obtenu les meilleurs résultats sur le protocole expérimental retenu. CLAHE homogénéise le contraste, tandis que le masque focalise l'analyse sur la région anatomiquement pertinente.
- **Le masque élimine le bruit contextuel** : En supprimant les contributions du fond, des os et des annotations, le masque permet au modèle de se concentrer sur les patterns pathologiques réels plutôt que sur des artefacts d'acquisition.
- **La validation quantitative guide les choix** : Les métriques objectives (variance intra-classe, test t) permettent de comparer rigoureusement les approches et d'éviter les décisions subjectives basées uniquement sur l'inspection visuelle.

5. Stratégie de modélisation

Les modèles de Machine Learning classiques et les modèles CNN testés s'appuieront sur des principes communs d'équilibrage des classes et, lorsque cela est pertinent, d'augmentation de données.

Compte tenu du fort déséquilibre entre les classes, le dataset sera rééquilibré avant ou pendant l'entraînement des modèles. D'une part, des **poids de classes** (*class weights*) seront calculés afin de donner davantage d'importance aux classes minoritaires lors de l'apprentissage. D'autre part, une stratégie de **data augmentation** sera appliquée, en utilisant des transformations anatomiquement plausibles, ainsi qu'une application éventuelle de **CLAHE** pour améliorer localement le contraste des radiographies.

Les amplitudes de rotation et de zoom seront volontairement limitées afin de rester compatibles avec la posture réelle des patients et de ne pas déformer la géométrie des poumons. Ces transformations reproduisent uniquement les variations usuelles de positionnement, de cadrage et d'exposition observées en pratique clinique.

Cette combinaison de pondération des classes, d'augmentation contrôlée et de correction de contraste doit permettre de réduire l'impact du déséquilibre des classes, d'améliorer la robustesse des modèles CNN et de favoriser une meilleure généralisation sur les données de validation et de test.

— Fin de la partie 1 : Exploration des données et prétraitement —

Partie II : Exploration des données

Dataset : COVID-19 Radiography Database
21 165 radiographies • 4 catégories diagnostiques

6. Rappel du pipeline de preprocessing

Ce rapport constitue la deuxième partie de l'analyse du dataset COVID-19 Radiography Database. La première partie a établi un pipeline de preprocessing optimal, validé par des métriques quantitatives. Avant d'aborder la modélisation, rappelons les étapes retenues :

Pipeline retenu : (1) Chargement en niveaux de gris → (2) Application de CLAHE (clipLimit=2.0, tileGridSize=8×8) → (3) Application du masque pulmonaire → (4) Redimensionnement (64×64 ou 128×128 selon le modèle) → (5) Normalisation [0, 1].

Pipeline de preprocessing et modélisation ML classique




Figure 18 : Pipeline de preprocessing et modélisation ML classique

Tous les modèles présentés dans ce rapport partagent ce même preprocessing, ce qui garantit une comparaison équitable. Le split utilisé est systématiquement 80/20 stratifié (random_state=42), et les évaluations sont réalisées sur le jeu de test (4 233 images).

Réflexion : La standardisation des conditions expérimentales est essentielle pour attribuer les différences de performance aux modèles eux-mêmes et non à des variations de preprocessing.

7. Extraction de caractéristiques

Les modèles de machine learning classiques ne peuvent pas traiter directement des images 2D. Il est nécessaire de transformer chaque radiographie en un vecteur numérique exploitable. Deux stratégies d'extraction ont été testées.

7.1 Pixels aplatis et réduction PCA

La première approche consiste à aplatir chaque image preprocessée en un vecteur 1D. Pour une image de 128×128 pixels, cela produit un vecteur de 16 384 dimensions ; pour 64×64, un vecteur de 4 096 dimensions. Ces espaces de très haute dimension posent un problème majeur : le fléau de la dimensionnalité (curse of dimensionality), qui dégrade les performances de la plupart des classifieurs.

Pour y remédier, une **Analyse en Composantes Principales (PCA)** est appliquée après standardisation (StandardScaler). La PCA projette les données dans un sous-espace de dimension réduite tout en conservant le maximum de variance. Après expérimentation, **200 composantes** ont été retenues, capturant environ **78,2 %** de la variance totale. Ce choix offre un bon compromis entre compression de l'information et préservation du signal discriminant.




Figure 19 : Variance expliquée cumulée par PCA — 200 composantes retenues

Réflexion : La PCA réduit la dimension de 16 384 à 200 (facteur $\times 82$), ce qui accélère considérablement l'entraînement tout en améliorant la généralisation grâce à l'élimination du bruit. La réduction à 200 composantes conserve environ 78,2 % de la variance totale. Bien qu'une partie de l'information soit perdue, cette réduction permet de diminuer significativement la dimension du problème tout en conservant l'essentiel de la structure globale des données. L'hypothèse retenue est que les composantes supprimées contiennent majoritairement des variations peu discriminantes pour la tâche de classification, sans qu'il soit possible de l'affirmer avec certitude.

7.2 Descripteurs HOG (Histogram of Oriented Gradients)

La seconde approche utilise les **descripteurs HOG**, une technique classique de vision par ordinateur particulièrement adaptée à la détection de structures et de contours. Contrairement aux pixels bruts, HOG capture les **gradients d'intensité locaux**, ce qui permet de représenter les textures et structures anatomiques des poumons de manière plus robuste.

Les paramètres utilisés sont : orientations=9, pixels_per_cell=(8,8), cells_per_block=(2,2), block_norm=L2-Hys, transform_sqrt=True. Sur des images 64×64, cela produit un vecteur de **1 764 dimensions**, soit une représentation nettement plus compacte que les 4 096 pixels aplatis, tout en étant plus informative sur le plan structurel.

8. Modèles de classification

Six familles de modèles de machine learning classiques ont été testées, avec différentes combinaisons de features et d'hyperparamètres. Chaque modèle utilise le même split train/test et le même préprocessing. La métrique principale retenue est le F1-macro, qui pénalise équitablement les erreurs sur chaque classe, indépendamment de sa fréquence. Ce choix est motivé par le fort déséquilibre du dataset.

8.1 Régression Logistique

Version baseline (pixels aplatis)

Le premier modèle testé est une régression logistique multinomiale (solver=saga, max_iter=5000) entraînée sur les pixels aplatis ($64 \times 64 = 4\,096$ features) après standardisation. Malgré 5 000 itérations, le modèle **n'a pas convergé**, ce qui indique que l'espace des pixels bruts est trop complexe et bruité pour ce classifieur linéaire. Les résultats sont modestes : **accuracy = 0,65** et **F1-macro = 0,61**. Le recall COVID n'est que de 0,27, signifiant que près de 3 cas COVID sur 4 ne sont pas détectés.

Version HOG (avec et sans SMOTE)

Le remplacement des pixels par des descripteurs HOG améliore significativement les résultats. La régression logistique atteint un **F1-macro de 0,72** (+11 points), avec un recall COVID qui bondit à **0,63**. L'application de **SMOTE** (Synthetic Minority Over-sampling Technique) sur le jeu d'entraînement n'apporte qu'un gain marginal (F1-macro de 0,72 identique, légère amélioration du recall Viral Pneumonia de 0,93 à 0,95).

Un **GridSearchCV** (CV=3, 12 candidats) a permis d'identifier les meilleurs hyperparamètres : penalty=elasticnet, C=1.0, l1_ratio=0.5 (CV F1-macro = 0,703). Les résultats finaux restent similaires sur le jeu de test.

Réflexion : HOG capture les structures anatomiques (contours des poumons, patterns de texture) que les pixels bruts ne représentent pas efficacement. Cette amélioration de +11 points confirme l'importance de l'extraction de features adaptée en ML classique.

8.2 Random Forest

L'impact de la représentation des données sur les performances : une première approche basée sur les pixels bruts (raw pixels), et une seconde approche basée sur des features extraites avec la méthode HOG (Histogram of Oriented Gradients).

Dans les deux cas, les images ont été prétraitées en extrayant la région pulmonaire via les masques, en les redimensionnant en 64×64 pixels, puis en appliquant une amélioration de contraste (CLAHE).

Pour chaque représentation, une phase de tuning des hyperparamètres a été réalisée à l'aide de GridSearchCV (validation croisée à 5 folds, métrique F1-macro). Cette étape a permis d'identifier les meilleures configurations tout en analysant le risque de surapprentissage (overfitting).

Dans la première approche, basée sur les pixels bruts (4096 features après aplatissement), le modèle Random Forest a montré un surapprentissage important lorsque des profondeurs élevées étaient utilisées (max_depth=10). Une configuration plus équilibrée a donc été sélectionnée manuellement (max_depth=8). Le modèle final atteint une **accuracy d'environ 0.65** et un **F1-macro de 0.62** sur le jeu de test.

Dans la seconde approche, descripteurs **HOG** (1764 features) ont été extraits afin de capturer les structures locales des images (contours et gradients). Après optimisation avec GridSearchCV, un modèle plus régularisé a été retenu pour limiter le surapprentissage. Le modèle final atteint une **accuracy d'environ 0.62** et un **F1-macro de 0.60**.

La comparaison entre les deux approches montre que l'utilisation des features HOG n'apporte pas d'amélioration significative des performances globales. Dans les deux cas, les résultats restent limités.

En particulier, la classe **COVID** est difficile à détecter. Avec les pixels bruts, le **recall** est de **0.39** et le **F1-score d'environ 0.41**. Avec les features **HOG**, une légère amélioration est observée (**recall = 0.46, F1 $\approx$ 0.47**), mais les performances restent insuffisantes pour une utilisation fiable en contexte médical.

En revanche, certaines classes comme Viral Pneumonia présentent un recall élevé (jusqu'à 0.90–0.94), ce qui montre que le modèle est capable de détecter certains patterns, mais échoue à généraliser correctement pour le COVID.

Ces résultats montrent que le Random Forest, même après optimisation avec GridSearchCV, reste limité pour cette tâche. Le problème principal ne provient pas du modèle lui-même, mais de la représentation des données.

Les pixels aplatis détruisent la structure spatiale des images, et les descripteurs **HOG** restent insuffisants pour capturer la complexité des motifs liés au COVID.

8.3 K-Nearest Neighbors (KNN)

Le KNN (k=7, weights=distance, métrique euclidienne) est combiné avec StandardScaler + PCA(200) dans un pipeline. La validation croisée (CV=3) donne un F1-macro moyen de 0,620 ($\pm$ 0,007). Sur le test, l'**accuracy est de 0,68** et le **F1-macro de 0,63**. Le KNN souffre particulièrement sur COVID (recall = 0,29) et Lung_Opacity (recall = 0,53), suggérant que la distance euclidienne dans l'espace PCA ne suffit pas à séparer ces classes qui partagent des caractéristiques visuelles proches.

Réflexion : La faiblesse du KNN sur les classes pathologiques étroites (COVID, Lung_Opacity) s'explique par la proximité de ces classes dans l'espace PCA : les opacités pulmonaires du COVID se confondent avec celles d'autres pathologies.

8.4 Support Vector Classifier SVC (SVM)

Le SVC (SVM) à noyau RBF est le modèle le plus performant de cette série. Deux configurations ont été testées :

Configuration 64×64 (avec GridSearchCV) : Un GridSearchCV (36 combinaisons, CV=3, scoring=f1_macro) identifie les meilleurs paramètres : PCA=200, C=10, gamma=scale. Le modèle atteint un **F1-macro de 0,74** (CV best = 0,728) et une accuracy de 0,75. Temps d'entraînement total du GridSearch : ~2h40.

Configuration 128×128 (paramètres fixés) : En augmentant la résolution d'entrée à 128×128 (16 384 pixels → PCA 200), les mêmes hyperparamètres optimaux produisent un **F1-macro de 0,75** et une accuracy de 0,75. Le recall COVID atteint 0,62, le meilleur de tous les modèles ML avec cette métrique. Temps d'entraînement final : ~104 secondes.

8.5 Gradient Boosting (HistGradientBoosting)

Le HistGradientBoostingClassifier de scikit-learn est testé avec PCA(200) sur des images 128×128. Paramètres : learning_rate=0.05, max_iter=300, max_leaf_nodes=31, early_stopping activé. La validation croisée (CV=3) donne un F1-macro de 0,656 (± 0,009). Sur le test, le modèle obtient un **F1-macro de 0,69** et une accuracy de 0,71. Le modèle s'arrête à 118 itérations (early stopping), indiquant un risque de surapprentissage au-delà.

8.6 XGBoost

XGBoost est configuré avec les paramètres suivants : objective=multi:softprob, learning_rate=0.05, max_depth=6, n_estimators=800 (early_stopping_rounds=30), subsample=0.8, colsample_bytree=0.8. L'entraînement utilise des sample_weights équilibrés avec un bonus de 10 % pour COVID. La validation croisée (CV=3) et l'évaluation finale donnent un **F1-macro de 0,72** et une accuracy de 0,74 sur le test. Le modèle converge à environ 300 itérations (early stopping). La précision COVID (0,61) est la meilleure de tous les modèles, mais au prix d'un recall plus faible (0,40).

Réflexion : Le compromis précision/recall du XGBoost est intéressant : il est le modèle le plus « prudent » dans ses diagnostics COVID (peu de faux positifs), mais rate davantage de vrais cas. En contexte médical, un recall élevé est généralement privilégié pour éviter les faux négatifs.

9. Synthèse comparative

9.1 Tableau récapitulatif

Le tableau ci-dessous rassemble les résultats de tous les modèles évalués sur le jeu de test (4 233 images, split 80/20 stratifié).

Modèle	Features	Resize	Accura	F1-macro	Recall CO	CV F1
LR (pixels)	Pixels	64×64	0,65	0,61	0,27	—
LR (HOG)	HOG	64×64	0,72	0,72	0,63	0,703
LR+SMOTE (HOG)	HOG	64×64	0,72	0,72	0,62	—
Random Forest	Pixels	64×64	0,65	0,62	0,39	0,63
Random Forest (HOG)	HOG	64×64	0,62	0,6	0,46	0,6
KNN + PCA	PCA(200)	64×64	0,68	0,63	0,29	0,620
Boosting + PCA	PCA(200)	128×128	0,71	0,69	0,44	0,656
XGBoost + PCA	PCA(200)	128×128	0,74	0,72	0,40	—
SVC (SVM) + PCA (64)	PCA(200)	64×64	0,75	0,74	0,57	0,728
SVC (SVM) + PCA (128)	PCA(200)	128×128	0,75	0,75	0,62	—

Tableau 1 : Résultats comparatifs de tous les modèles ML classiques




Figure 20 : Comparaison des modèles ML classiques — F1-macro et Accuracy (test)

9.2 Analyse par classe : le problème COVID

L'analyse détaillée par classe révèle un constat récurrent : **la classe COVID est systématiquement la plus difficile à classifier**. Quel que soit le modèle, le F1-score COVID oscille entre 0,33 et 0,56, loin derrière Normal (0,75–0,83) et Viral Pneumonia (0,77–0,88). Cette difficulté s'explique par la forte similarité visuelle entre les opacités pulmonaires COVID et celles de la classe Lung_Opacity : les matrices de confusion montrent systématiquement une confusion bilatérale entre ces deux classes.




Figure 21 : F1-score par classe et par modèle — COVID systématiquement en retrait




Figure 22 : Recall et Precision COVID-19 par modèle — enjeu de détection




Figure 23 : Matrice de confusion du meilleur modèle (SVC/SVM + PCA, 128×128)

Réflexion : Les modèles HOG-LR et SVC/SVM-128 atteignent les meilleurs recall (~0,62–0,63), mais manquent encore près de 40 % des cas COVID. Cela motive le recours au deep learning pour capturer des patterns plus fins.

9.3 Impact de la résolution d'image

La comparaison du SVC (SVM) à deux résolutions (64×64 vs 128×128) montre un gain modeste mais systématique en passant à 128×128 : le F1-macro passe de 0,74 à 0,75, et le recall COVID de 0,57 à 0,62. Ce gain s'explique par la préservation de détails anatomiques plus fins lors du redimensionnement. Toutefois, cette amélioration a un coût : l'espace mémoire quadruple (de 4 096 à 16 384 features avant PCA), ce qui impose un compromis entre performance et ressources computationnelles.

10. Conclusion et prochaines étapes

L'exploration systématique de six familles de modèles ML classiques permet de tirer plusieurs enseignements clés :

Le SVC (SVM) à noyau RBF + PCA(200) est le meilleur modèle ML classique avec un F1-macro de 0,75 et une accuracy de 0,75. Sa capacité à modéliser des frontières de décision non linéaires dans l'espace PCA explique sa supériorité sur les autres approches.

L'extraction de features adaptée est déterminante : le passage des pixels bruts aux descripteurs HOG (+11 points de F1-macro pour la LR) ou à une PCA bien dimensionnée améliore considérablement les performances. Les pixels aplatis seuls sont insuffisants pour les classifieurs linéaires.

La classification COVID reste le point faible majeur : aucun modèle ML classique ne dépasse un F1 COVID de 0,56, et le meilleur recall COVID est de 0,63. La confusion avec Lung_Opacity est structurelle et ne peut être résolue par de simples features de bas niveau.

Le déséquilibre des classes a été atténué par `class_weight=balanced` et SMOTE, mais ces techniques ne résolvent pas le problème fondamental de similarité inter-classe.

— Fin de la partie 2 : Modélisation ML classique —

Partie 3: Modélisation par Deep Learning

Dataset : COVID-19 Radiography Database
21 165 radiographies • 4 catégories diagnostiques

11. Objectif de la phase Deep Learning

Après l'analyse exploratoire des données et la mise en œuvre des premiers modèles de Machine Learning, une phase de Deep Learning a été développée afin d'exploiter pleinement l'information visuelle contenue dans les radiographies thoraciques.

L'objectif principal est de classifier automatiquement les examens radiologiques en quatre catégories :

- COVID-19
- Normal
- Lung Opacity
- Viral Pneumonia

Bien que le problème soit formulé comme une classification multiclasse, une attention particulière est portée à la détection de la classe COVID-19.

Cette phase vise donc à répondre à la problématique suivante :

Quelle architecture de Deep Learning permet d'obtenir le meilleur compromis entre performance globale et détection fiable des cas COVID-19 ?

12. Pipeline expérimental commun

Afin de garantir une comparaison rigoureuse entre les différentes architectures étudiées, l'ensemble des expérimentations repose sur un protocole identique.

12.1 Jeu de données

Le découpage est figé ainsi pour l'ensemble des expériences :

Split	COVID	Normal	Lung_Opacity	Viral_Pneumonia	Total
Train	2531	7134	4208	942	14815
Validation	543	1529	902	201	3175
Test	542	1529	902	202	3175
Total	3616	10192	6012	1345	21165

Cette stratégie garantit la reproductibilité des résultats et permet une comparaison équitable entre les modèles.

Tous les modèles sont évalués sur exactement les mêmes ensembles d'entraînement, validation et test. Cette stratégie de fixed split garantit une comparaison équitable des architectures puisque les écarts de performance observés proviennent uniquement des modèles et non d'une variation du découpage des données.

12.2 Prétraitement des données

Chaque radiographie subit plusieurs opérations de préparation :

- application d'un masque pulmonaire
- suppression des régions hors poumons
- redimensionnement des images
- conversion RGB pour les architectures pré-entraînées
- normalisation des intensités

Pour certaines expérimentations:

- application du CLAHE
- Data Augmentation:
 - rotations
 - translations
 - zooms
 - variations de luminosité
- Le masquage pulmonaire vise à concentrer l'apprentissage sur les régions anatomiques pertinentes et à limiter l'influence des artefacts présents dans les radiographies.

Dans une démarche de validation expérimentale, nous avons choisi d'évaluer chaque architecture selon deux variantes afin de mesurer l'apport respectif du CLAHE et de l'augmentation de données sur les performances:

- CLAHE désactivé et data augmentation désactivée
- CLAHE activé et data augmentation activée.

12.3 Gestion du déséquilibre des classes

Le dataset présente un déséquilibre important entre les catégories.

Afin d'éviter que les modèles privilégient les classes majoritaires, des poids de classes sont calculés à partir du jeu d'entraînement.

Cette stratégie augmente la pénalisation des erreurs commises sur les classes sous-représentées, notamment:

- COVID-19 (3616)
- Viral Pneumonia (1345)

12.4 Métriques d'évaluation

Dans un contexte médical, l'accuracy seule est insuffisante.

L'évaluation repose donc sur plusieurs indicateurs complémentaires:

- Accuracy
- Precision
- Recall
- F1-score
- Macro F1
- Weighted F1

Le critère principal retenu pour comparer les architectures est le Macro F1-score. Cette métrique accorde le même poids à chaque classe indépendamment de sa fréquence dans le dataset. Elle est particulièrement adaptée à notre problème en raison du déséquilibre entre les catégories Normal, COVID-19, Lung Opacity et Viral Pneumonia. Elle permet d'éviter qu'une bonne performance sur la classe majoritaire masque des difficultés sur les classes minoritaires.

Une attention particulière sera aussi portée au: Recall COVID qui mesure la capacité du système à détecter les patients réellement atteints.

13. Étude des architectures évaluées

L'objectif de cette section est de présenter les différentes architectures étudiées ainsi que leur intérêt dans le cadre de la classification de radiographies pulmonaires.

13.1 Réseau Dense : modèle de référence

Le premier modèle développé repose sur un réseau de neurones entièrement connecté (Dense Neural Network).

Après prétraitement, chaque image de taille 128×128 pixels est convertie en un vecteur de 16 384 valeurs grâce à une couche Flatten.

L'information est ensuite propagée à travers plusieurs couches denses avant d'être classifiée par une couche Softmax.

Principe

Dans un réseau dense, chaque neurone est connecté à l'ensemble des neurones de la couche précédente. Cette architecture est efficace pour des données tabulaires mais présente une limite importante pour le traitement d'images : elle ignore totalement l'organisation spatiale des pixels.

Ainsi, deux pixels voisins dans l'image n'ont plus aucune relation particulière après l'opération Flatten.

Intérêt dans notre étude

Ce modèle sert principalement de baseline et permet de mesurer l'apport réel des architectures convolutionnelles développées par la suite.

13.2 CNN personnalisé

Le CNN personnalisé constitue la première architecture spécifiquement conçue pour le traitement d'images médicales.

Contrairement au réseau Dense, il conserve la structure spatiale des radiographies grâce à l'utilisation de couches convolutionnelles.

Principe des convolutions

Une couche convolutionnelle applique un filtre de petite taille sur l'ensemble de l'image.

Ces filtres apprennent progressivement à détecter :

- contours
- textures
- formes
- opacités pulmonaires

Les premières couches extraient des caractéristiques simples tandis que les couches profondes apprennent des représentations plus complexes.

Architecture retenue

Le modèle est composé de :

- quatre blocs convolutionnels
- Batch Normalization
- Max Pooling
- Dropout
- Global Average Pooling
- couche Softmax finale

Intérêt

Cette architecture permet d'évaluer les performances d'un CNN entraîné entièrement sur les radiographies sans utiliser de connaissances préalablement acquises.

13.3 DenseNet121

DenseNet121 est une architecture de transfert d'apprentissage particulièrement populaire en imagerie médicale.

Principe

La principale innovation de DenseNet réside dans les connexions denses entre les couches.

Chaque couche reçoit comme entrée:

- les caractéristiques extraites par la couche précédente
- mais également celles produites par toutes les couches antérieures

Cette stratégie améliore :

- la circulation de l'information
- la propagation du gradient
- la réutilisation des caractéristiques

Intérêt médical

Les lésions pulmonaires liées au COVID sont souvent diffuses et peu contrastées.

La capacité de DenseNet à conserver des détails fins constitue donc un avantage important.

13.4 EfficientNetB0

EfficientNet représente une génération plus récente de réseaux convolutionnels.

Principe

Les architectures classiques augmentent généralement:

- la profondeur
- ou la largeur
- ou la résolution

EfficientNet propose une approche appelée Compound Scaling qui optimise simultanément ces trois dimensions.

Avantages

- moins de paramètres
- coût de calcul réduit
- bonnes performances de généralisation

Intérêt dans le projet

L'objectif était de déterminer si une architecture plus récente pouvait améliorer la détection du COVID tout en restant légère pour un futur déploiement.

13.5 ResNet50

ResNet50 introduit le concept de connexions résiduelles.

Principe

Dans les réseaux profonds, les gradients peuvent devenir très faibles lors de l'apprentissage.

Les connexions résiduelles permettent à l'information de contourner certaines couches.

Le réseau apprend $F(x) + x$ plutôt que simplement $F(x)$.

Avantages

- entraînement de réseaux très profonds
- meilleure stabilité
- réduction du phénomène de disparition du gradient

Intérêt médical

Cette architecture est souvent utilisée pour les tâches de classification radiologique grâce à sa robustesse.

13.6 VGG16

VGG16 est une architecture de réseau neuronal convolutif profond qui a gagné en popularité grâce à sa simplicité et son efficacité dans les tâches de classification d'images.

Principe

Le réseau repose sur l'empilement de filtres convolutionnels 3×3 .

Malgré sa simplicité, cette approche permet d'extraire progressivement des caractéristiques visuelles de plus en plus complexes.

Architecture

VGG16 comporte :

- 13 couches convolutionnelles
- 3 couches entièrement connectées

- environ 138 millions de paramètres dans sa version originale

Dans notre projet, seule la partie convolutionnelle pré-entraînée est conservée.

Une nouvelle tête de classification est ajoutée puis adaptée à notre problème par fine-tuning.

Pourquoi VGG16 ?

Malgré son ancienneté, VGG16 présente plusieurs avantages :

- architecture simple à interpréter
- stabilité de l'apprentissage
- bonnes performances sur le rappel COVID
- cartes Grad-CAM particulièrement lisibles

Ces caractéristiques ont conduit à son choix comme modèle final.

14. Comparaison des architectures étudiées

L'objectif n'était pas uniquement d'obtenir la meilleure accuracy mais d'identifier le modèle offrant le meilleur compromis entre :

- sensibilité COVID
- robustesse
- généralisation
- interprétabilité

14.1. Modèle Dense : point de départ

Le premier modèle développé repose sur un réseau dense classique. Cette architecture sert principalement de référence expérimentale.

Les résultats obtenus montrent rapidement les limites de cette approche :

Métrique	Valeur
Accuracy	68,8 %
F1 COVID	43,4 %

La couche Flatten supprime totalement l'information spatiale présente dans les radiographies.

Le modèle peine ainsi à distinguer les différentes pathologies pulmonaires et génère un nombre important de faux négatifs COVID.

Cette expérimentation confirme que la structure spatiale de l'image constitue une information essentielle en imagerie médicale.

14.2. CNN personnalisé

Afin d'exploiter les caractéristiques visuelles locales des radiographies, un CNN spécifique a été développé.

L'introduction des couches convolutionnelles permet:

- l'extraction automatique de motifs pulmonaires
- la conservation de l'organisation anatomique
- la détection des textures associées aux lésions

Les performances progressent fortement :

Métrique	Valeur
Accuracy	87,8 %
F1 COVID	79,0 %
Recall COVID	69,9 %

Cette amélioration de près de 19 points d'accuracy démontre l'intérêt majeur des réseaux convolutionnels pour l'analyse des radiographies thoraciques.

14.3. Architectures de transfert d'apprentissage

Le transfert d'apprentissage permet d'accélérer la convergence et de bénéficier de représentations visuelles déjà optimisées.

Les modèles ont été entraînés selon une stratégie en deux phases :

1. Feature Extraction
2. Fine-Tuning progressif

14.4 Résultats comparatifs

Modèle	Accuracy	F1 COVID
Dense Baseline	68,8 %	43,4 %
CNN personnalisé*	87,8 %	79,0 %

EfficientNetB0*	85,5 %	75,9 %
ResNet50*	85,9 %	74,9 %
VGG16*	88,6 %	81,40 %

***Modèle sans CLAHE ni Data augmentation**

L'analyse montre que plusieurs architectures atteignent des performances globales relativement proches sauf pour Dense Baseline comme nous l'avons vu précédemment.

Cependant, dans un contexte médical, la capacité à détecter les patients atteints reste prioritaire.

15. Influence du CLAHE et de la Data Augmentation

Objectif

Au-delà du choix de l'architecture, une analyse spécifique a été menée afin d'évaluer l'impact du CLAHE et de l'augmentation artificielle des données sur les performances des modèles.

Deux configurations ont été comparées :

- Configuration A :
 - Masquage pulmonaire uniquement
 - Sans CLAHE
 - Sans Data Augmentation
- Configuration B :
 - Masquage pulmonaire
 - CLAHE
 - Data Augmentation

L'objectif est de déterminer si ces techniques améliorent réellement la capacité des modèles à détecter les cas COVID-19.

15.1. CNN custom

Le CNN custom obtient des résultats très solides:

- sans CLAHE ni augmentation : Accuracy 0,878 et Macro-F1 0,873
- avec CLAHE et augmentation : Accuracy 0,875 et Macro-F1 0,872

Le gain global est donc quasi nul, mais la variante augmentée relève nettement le recall COVID : 0,792 avec CLAHE et augmentation contre 0,699.

Cette architecture présente donc un profil intéressant : une bonne base de référence, très compétitive, avec un arbitrage clair entre équilibre global et sensibilité COVID.

15.2. EfficientNetB0

EfficientNetB0 reste correct mais ne domine pas sur ce jeu de données.

- Sans CLAHE ni augmentation : Accuracy 0,855 et Macro-F1 0,846
- Avec CLAHE et augmentation : Accuracy descend à 0,827 et le Macro-F1 à 0,821.

Le recall COVID progresse en revanche de 0,745 à 0,780 avec CLAHE et augmentation.

La lecture la plus cohérente est la suivante : la variante augmentée rend le modèle plus sensible à la classe COVID, mais au prix d'un affaiblissement de la cohérence multiclassés globale.

15.3. DenseNet121

DenseNet121 est l'architecture qui souffre le plus de la variante CLAHE + augmentation dans cette étude.

Sans ces traitements, le modèle atteint accuracy 0,839 et Macro-F1 0,830 ; avec eux, il tombe à 0,787 et 0,769.

Le rappel COVID baisse aussi, de 0,780 à 0,760, tandis que le rappel Lung_Opacity décroche davantage encore.

Le comportement observé suggère ici une dégradation de la séparabilité, en particulier entre les opacités pulmonaires et les autres motifs pathologiques.

15.4. ResNet50

ResNet50 offre un comportement stable et compétitif.

La variante sans CLAHE ni augmentation produit accuracy 0,859 et Macro-F1 0,855, contre 0,830 et 0,815 pour la variante avec traitements.

Le rappel COVID y est également meilleur sans CLAHE/augmentation : 0,773 contre 0,664.

Dans ce protocole, ResNet50 confirme qu'il s'agit d'une valeur sûre, mais il reste derrière VGG16 et légèrement derrière le CNN custom sans prétraitements additionnels.

15.5. VGG16

VGG16 domine l'étude selon deux critères différents: meilleur équilibre global d'un côté, meilleure sensibilité COVID de l'autre.

La variante de VGG16 sans CLAHE ni augmentation obtient le meilleur score global de l'étude : accuracy 0,886 ; Macro-F1 0,880 ; F1-weighted 0,885.

La variante avec CLAHE et augmentation reste très proche : accuracy 0,877 ; Macro-F1 0,875 ; mais elle devient la meilleure sur le rappel COVID avec 0,825.

15.6. Synthèse des effets

Le classement montre clairement deux enseignements. D'une part, les deux variantes VGG16 dominent les autres architectures sur le protocole retenu. D'autre part, le CNN custom n'est pas un simple témoin: sa variante sans CLAHE ni augmentation se place troisième, devant ResNet50, EfficientNetB0 et DenseNet121.

L'intérêt de tester systématiquement les variantes avec et sans CLAHE/augmentation est précisément de sortir du discours générique selon lequel ces traitements seraient toujours bénéfiques. Les résultats montrent une réalité plus nuancée.

L'ajout de transformations supplémentaires ne semble pas apporter de bénéfice global et peut, dans certains cas, introduire une variabilité défavorable à l'apprentissage.

En revanche, certaines architectures présentent une amélioration du rappel de la classe COVID, mettant en évidence un compromis entre performance globale et sensibilité à cette classe.

Un résultat notable concerne le CNN personnalisé. Malgré l'absence de pré-entraînement sur ImageNet, cette architecture atteint des performances comparables, voire supérieures, à plusieurs modèles de transfert d'apprentissage. Ces résultats suggèrent que les caractéristiques discriminantes des radiographies pulmonaires peuvent être apprises efficacement à partir du dataset étudié lorsque le prétraitement et l'architecture sont adaptés à la tâche.

16. Choix du modèle final

16.1. Critères de choix

Le choix du modèle final repose sur plusieurs critères complémentaires :

- les performances quantitatives
- les performances sur la classe COVID-19
- la stabilité de l'apprentissage
- la capacité de prédictions
- l'interprétabilité des prédictions

Le CNN personnalisé et VGG16 obtiennent des résultats proches. Le CNN personnalisé atteint une accuracy de **87,8 %** et un Macro-F1 de **0,873**, contre respectivement **88,6 %** et **0,880** pour VGG16.

Toutefois, plusieurs éléments justifient la sélection de VGG16 :

1. Il présente les meilleures performances globales parmi les architectures évaluées.
2. Les courbes d'apprentissage montrent une convergence plus stable, suggérant une meilleure généralisation.
3. Le transfert d'apprentissage à partir d'ImageNet facilite l'extraction de caractéristiques discriminantes malgré la différence de domaine entre images naturelles et radiographies thoraciques.
4. Les visualisations Grad-CAM indiquent une focalisation cohérente sur les régions pulmonaires pertinentes.

Par ailleurs, la version de VGG16 utilisant CLAHE et la Data Augmentation obtient le meilleur recall COVID, ce qui peut constituer un avantage dans un contexte où la réduction des faux négatifs est prioritaire.

16.1.1. Performances quantitatives du modèle retenu

L'écart entre VGG 16 et le modèle CNN personnalisé sans prétraitement reste toutefois limité :

- Accuracy : +0,8 point en faveur de VGG16
- Macro-F1 : +0,7 point en faveur de VGG16.

Le tableau suivant synthétise les résultats obtenus sur l'ensemble de tests.

Modèle	CLAHE	Augmentatio	Accuracy	Macro-F1	F1-weighte	Recall COVI	F1 COVID
VGG16	Non	Non	0.886	0.880	0.885	0.810	0.814
VGG16	Oui	Oui	0.877	0.875	0.877	0.825	0.802
CNN custom	Non	Non	0.878	0.873	0.877	0.699	0.790
CNN custom	Oui	Oui	0.875	0.872	0.875	0.792	0.794
ResNet50	Non	Non	0.859	0.855	0.859	0.773	0.749
EfficientNetB	Non	Non	0.855	0.846	0.854	0.745	0.759
DenseNet12	Non	Non	0.839	0.830	0.841	0.780	0.710
EfficientNetB	Oui	Oui	0.827	0.821	0.829	0.780	0.697
ResNet50	Oui	Oui	0.830	0.815	0.827	0.664	0.700
DenseNet12	Oui	Oui	0.787	0.769	0.793	0.760	0.630

16.1.2. Compromis entre recall COVID et Macro-F1.

Ces résultats montrent que VGG16 offre le meilleur compromis entre performances globales, détection des cas COVID-19 et homogénéité des performances entre les différentes classes.




Figure 2 – Compromis entre recall COVID et Macro-F1.

16.1.3. La stabilité de l'apprentissage

Analyse des courbes d'entraînement : loss/val_loss et accuracy/val_accuracy


Globalement, les courbes montrent que tous les modèles apprennent : la loss d'entraînement diminue progressivement et l'accuracy d'entraînement augmente. Cependant, la vraie différence entre les modèles apparaît surtout sur la **validation loss**. Un bon modèle n'est pas seulement celui dont l'accuracy train augmente, mais celui dont la val_loss diminue puis reste stable.

Les meilleures courbes sont celles de **VGG16 sans CLAHE ni augmentation** et du **CNN custom sans CLAHE ni augmentation**. Elles atteignent les plus faibles val_loss, respectivement environ **0,322** pour VGG16 F/F et **0,326** pour CNN custom F/F. Cela signifie que ces deux modèles généralisent bien sur le jeu de validation, avec une séparation correcte entre les classes.


À l'inverse, certains modèles continuent à améliorer leur accuracy d'entraînement alors que la validation ne progresse plus réellement. C'est peut être le signe d'un début de **surapprentissage**.

Ce phénomène est visible surtout sur **ResNet50 F/F** et, dans une moindre mesure, sur **VGG16 F/F** : l'accuracy train finale devient très élevée, mais l'écart avec la validation augmente.

CNN Sans Clahe ni data augmentation :



VGG16 Sans Clahe ni data augmentation :



16.1.4. La capacité de prédictions

Matrice de confusion

Les matrices de confusion montrent que les erreurs ne sont pas réparties au hasard. Elles se concentrent principalement entre les classes pathologiques proches :

COVID ↔ Lung_Opacity

C'est la confusion la plus importante médicalement et visuellement. Les deux classes présentent des opacités pulmonaires parfois proches, ce qui explique que certains cas COVID soient prédits comme Lung_Opacity, et inversement.

COVID → Normal

C'est l'erreur la plus critique dans une logique de dépistage, car elle correspond à un faux négatif COVID interprété comme radiographie normale. Dans un contexte médical, le recall COVID est donc prioritaire, car il limite les cas COVID manqués.


Normal ↔ Lung_Opacity

Cette confusion existe aussi, mais elle est généralement moins problématique que COVID → Normal. Elle traduit surtout la difficulté à distinguer certaines radiographies normales avec variations anatomiques ou contraste faible de radiographies avec opacités légères.

Viral Pneumonia


Cette classe est globalement bien reconnue par presque tous les modèles. Les erreurs sur Viral Pneumonia restent limitées, ce qui montre que ses motifs visuels sont plus distinctifs dans ce dataset.

a- CNN FALSE FALSE



La matrice présente une forte concentration sur la diagonale, indiquant une bonne capacité de classification.

b- VGG FALSE FALSE



Les principales erreurs concernent les classes Covid et Lung_Opacity avec une légère augmentation comparé à CNN. Le classe normal est légèrement mieux distinguée ainsi que Viral Penumonia.

L'analyse des matrices de confusion confirme que la difficulté principale du problème ne vient pas de toutes les classes de manière homogène, mais surtout de la séparation entre COVID et Lung_Opacity.

La variante VGG16 T/T est légèrement moins performante globalement, mais elle détecte davantage de cas COVID. Elle réduit le nombre de faux négatifs COVID de 103 à 95, ce qui la rend intéressante dans une logique de dépistage où la sensibilité COVID est prioritaire. En contrepartie, elle augmente le nombre de faux positifs COVID.

Les modèles DenseNet121 T/T et EfficientNetB0 T/T deviennent trop permissifs envers la classe COVID : ils classent trop d'images Lung_Opacity ou Normal comme COVID. À l'inverse, le CNN custom F/F est très prudent, avec peu de faux positifs COVID, mais il manque trop de vrais cas COVID. Cette opposition montre bien le compromis classique entre précision COVID et rappel COVID.

En conclusion, les matrices de confusion confirment le choix de VGG16 F/F comme modèle final pour une classification multiclassées équilibrée, et de VGG16 T/T comme variante orientée vers une meilleure sensibilité COVID.

16.2. Choix retenu

Deux scénarios peuvent être envisagés.

Scénario A : performance multiclasss globale

Le modèle VGG16 sans CLAHE ni Data Augmentation obtient :

- meilleur Macro F1 ;
- meilleur F1 pondéré.

Il constitue donc le meilleur modèle global.

Scénario B : priorité à la détection du COVID

Lorsque l'objectif principal devient la réduction des faux négatifs COVID, la variante VGG16 avec CLAHE et Data Augmentation devient particulièrement intéressante puisqu'elle obtient le meilleur Recall COVID de l'ensemble des architectures évaluées.

Le choix final dépend donc du compromis recherché entre performance multiclassse et sensibilité clinique.

Dans le cadre de ce projet, le **scénario A** a été retenu car l'objectif consiste à développer un système multiclassse robuste tout en conservant un excellent niveau de détection du COVID.

17. Interprétabilité des prédictions

Afin d'améliorer la transparence du système, une analyse d'explicabilité est réalisée à l'aide de Grad-CAM.

L'un des critères ayant motivé le choix final concerne la capacité du modèle à produire des visualisations interprétables via Grad-CAM. Dans le domaine médical, il est essentiel de pouvoir comprendre les régions anatomiques ayant conduit à une décision. Les cartes d'activation générées permettent ainsi de vérifier que les prédictions reposent bien sur les zones pulmonaires présentant des anomalies radiologiques.

Cette méthode génère une carte thermique mettant en évidence les régions de l'image ayant le plus influencé la décision du réseau.

L'objectif est double :


- comprendre le comportement du modèle
- vérifier la cohérence clinique des prédictions

Les analyses ci-dessous ont été réalisées sur :


- le CNN personnalisé
- le modèle final VGG16

COVID | correct | Vrai=COVID | Prédit=COVID | conf=1.000

Original
Classe=COVID




Grad-CAM
Classe prédite=COVID




CNN_CUSTOM's Grad-CAM sur radiographie COVID correctement classifiée

COVID | incorrect | Vrai=COVID | Prédit=Lung_Opacity | conf=0.997


Original
Vrai=COVID



Grad-CAM classe prédite
Lung_Opacity




Grad-CAM vraie classe
COVID




CNN_CUSTOM's Grad-CAM sur radiographie COVID incorrectement classifiée

COVID | correct | Vrai=COVID | Prédit=COVID | conf=1.000
Backbone=vgg16 | couche Grad-CAM=block5_conv3

Original
Classe=COVID



Grad-CAM classe prédite
COVID




VGG16's Grad-CAM sur radiographie COVID correctement classifiée

COVID | incorrect | Vrai=COVID | Prédit=Normal | conf=0.991
Backbone=vgg16 | couche Grad-CAM=block5_conv3


Original
Vrai=COVID



Grad-CAM classe prédite
Normal



Grad-CAM vraie classe
COVID



VGG16's Grad-CAM sur radiographie COVID incorrectement classifiée

L'analyse Grad-CAM montre que globalement le modèle concentre l'essentiel de son attention sur les zones pulmonaires et non sur le fond de l'image. C'est un résultat important, car il réduit le risque que le CNN s'appuie sur des artefacts périphériques ou sur des indices de contexte non médicaux. Cette cohérence constitue un élément important pour renforcer la confiance dans le système développé.

Les erreurs les plus structurantes restent néanmoins les confusions COVID / Lung Opacity. Elles ne doivent pas être présentées comme un simple défaut technique, mais comme une difficulté cliniquement plausible, certaines signatures radiographiques pouvant être partiellement recouvrantes.

18. Analyse des erreurs

L'analyse des matrices de confusion met en évidence un phénomène récurrent : la majorité des erreurs concerne les classes COVID-19 et Lung Opacity.

Cette confusion est cohérente d'un point de vue radiologique. Comme expliqué précédemment, les deux pathologies peuvent présenter des opacités diffuses, des infiltrats bilatéraux ainsi qu'une atteinte du parenchyme pulmonaire visuellement proche sur une radiographie standard.

Les erreurs observées ne doivent donc pas être interprétées uniquement comme une faiblesse algorithmique mais également comme une conséquence de la proximité clinique entre certaines catégories diagnostiques.

À l'inverse, les classes Normal et Viral Pneumonia présentent des signatures radiologiques plus distinctes, ce qui explique leurs meilleurs scores de rappel.

Cette observation suggère que les améliorations futures devront prioritairement cibler la discrimination fine entre COVID-19 et les autres opacités pulmonaires plutôt que l'amélioration globale de la classification.

19. Discussion et limites

Les métriques utilisées lors de l'évaluation du preprocessing (variance intra-classe, tests statistiques et séparabilité des distributions) indiquent un avantage théorique de l'approche CLAHE + masque. Toutefois, les expérimentations Deep Learning montrent que cette amélioration statistique ne se traduit pas systématiquement par un gain de performance en classification. Cette observation souligne qu'une amélioration des propriétés globales des images n'implique pas nécessairement une amélioration des représentations apprises par les réseaux convolutionnels.

Les résultats obtenus confirment l'intérêt des réseaux convolutionnels pour l'analyse des radiographies thoraciques.

L'ensemble des architectures Deep Learning dépasse largement les performances du modèle Dense baseline.

Toutefois plusieurs limites doivent être soulignées :

- déséquilibre du dataset
- proximité radiologique entre COVID-19 et Lung Opacity
- absence de validation croisée
- dépendance à la qualité des masques pulmonaires
- absence d'évaluation sur des données externes.

Pour des contraintes de temps d'entraînement et de ressources matérielles, les images ont été redimensionnées en 128 × 128 pixels. Ce choix réduit la complexité du calcul mais peut également entraîner une perte d'informations fines potentiellement utiles à la détection de certaines anomalies pulmonaires.

Ces éléments constituent des pistes d'amélioration pour des travaux futurs.

Une piste d'amélioration consiste à poursuivre l'optimisation du modèle VGG16 retenu. Plusieurs leviers peuvent être explorés : ajustement du learning rate lors du fine-tuning, calibration des seuils de décision ou pondération plus forte de la classe COVID afin d'améliorer encore la sensibilité du système. Malgré les performances obtenues, plusieurs limitations doivent être prises en compte avant d'envisager une utilisation clinique du système proposé.

20. Conclusion

Un résultat particulièrement intéressant de cette étude concerne l'impact du prétraitement. Contrairement aux attentes initiales, l'application systématique du CLAHE et de la Data Augmentation n'a pas conduit à une amélioration généralisée des performances. Cette observation souligne l'importance de valider expérimentalement chaque choix méthodologique plutôt que de considérer certaines pratiques comme universellement bénéfiques.

Cette phase de Deep Learning a permis d'évaluer plusieurs architectures de classification appliquées aux radiographies pulmonaires. Les résultats obtenus montrent que la préservation de l'information spatiale constitue un facteur déterminant pour la détection des atteintes pulmonaires liées au COVID-19.

Après comparaison de plusieurs modèles de référence et de transfert d'apprentissage, VGG16 a été retenu comme solution finale en raison de son équilibre entre performances globales, rappel sur la classe COVID, score Macro F1 et capacité d'interprétation.

L'intégration de techniques d'explicabilité telles que Grad-CAM renforce l'intérêt du modèle dans une perspective d'aide au diagnostic médical en permettant de visualiser les régions influençant la décision du réseau. Ces résultats ouvrent la voie à de futurs travaux portant sur des jeux de données plus diversifiées et représentatifs des conditions cliniques réelles.

21. ANNEXES

GitHub Repository

https://github.com/mar25-ia2-radiographies/mar25_radiographies_pulmonaires_covid19/tree/main/notes


Résultats Consolidés Complets

Architecture	AHE	Augmentation	Accuracy	cro-F1	weighted	VID précision	VID recall	VID F1	Normal recall	lung Opacity recall	all Pneumonia
N custom	n	n	78	73	77	97	99	90	27	92	21
N custom	i	i	75	72	75	96	92	94	14	51	06
enseNet121	n	n	39	30	41	52	80	10	90	63	55
enseNet121	i	i	87	69	93	38	60	30	42	74	55
icientNetB0	n	n	55	46	54	74	45	59	95	34	41
icientNetB0	i	i	27	21	29	29	80	97	80	38	41
sNet50	n	n	59	55	59	26	73	49	22	98	91
sNet50	i	i	30	15	27	39	64	00	26	43	41
G16	n	n	86	80	85	19	10	14	56	08	16
G16	i	i	77	75	77	80	25	02	20	20	46


Analyse ROC et AUC

L'aire sous la courbe ROC (AUC) permet d'évaluer la capacité du modèle à distinguer les différentes classes indépendamment du seuil de décision choisi. Nous l'avons analysé pour les deux modèles CNN Custom et VGG 16.


a- CNN FALSE FALSE



b- VGG FALSE FALSE



c- Les deux modèles pour la classe COVID



Pour la classe COVID-19, le CNN personnalisé obtient une AUC de **0,9693**, tandis que VGG16 atteint **0,9694**.

Ces valeurs, très proches de 1, témoignent d'une excellente capacité de discrimination entre les radiographies COVID-19 et les autres catégories. L'écart observé entre les deux modèles est extrêmement faible (0,0001), indiquant des performances pratiquement équivalentes pour cette tâche spécifique.

Les résultats de l'analyse ROC confirment ainsi que les deux architectures disposent d'un fort pouvoir discriminant. L'avantage de VGG16 ne provient donc pas d'une amélioration majeure de l'AUC, mais plutôt de ses performances globales légèrement supérieures et de sa meilleure homogénéité entre les classes

Références

<https://www.who.int/health-topics/coronavirus>

<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0242958>

<https://pubs.rsna.org/doi/10.1148/radiol.2020201160>

<https://pubs.rsna.org/doi/10.1148/radiol.2020200527>

<https://www.who.int/publications/i/item/use-of-chest-imaging-in-covid-19>

[https://www.clinicalimaging.org/article/S0899-7071\(20\)30101-7/fulltext](https://www.clinicalimaging.org/article/S0899-7071(20)30101-7/fulltext)

<https://ieeexplore.ieee.org/document/9144185>

<https://arxiv.org/abs/2003.13865>

<https://arxiv.org/abs/1711.05225>

<https://arxiv.org/abs/2601.00837>

<https://radiopaedia.org/articles/normal-chest-imaging-examples>

<https://pubmed.ncbi.nlm.nih.gov/29757717/>

<https://pubmed.ncbi.nlm.nih.gov/18195376/>

<https://ieeexplore.ieee.org/document/9144185>

<https://www.sciencedirect.com/science/article/pii/S001048252100113X>

<https://www.sciencedirect.com/science/article/abs/pii/S0020025523014391>

https://www.researchgate.net/publication/399470150_Deep_Learning_for_Chest_X-Ray_Classification_A_Comprehensive_Review_of_Methods_Advances_and_Clinical_Integration

https://www.researchgate.net/publication/354951103_Public_Covid-19_X-ray_datasets_and_their_impact_on_model_bias_-_A_systematic_review_of_a_significant_problem

<https://www.nature.com/articles/s41598-024-61693-0>

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11822832/>

<https://www.mdpi.com/2313-433X/10/10/250>

<https://esmed.org/ensemble-deep-learning-for-chest-x-ray-disease-detection/>

<https://www.emergentmind.com/topics/chexnet-densenet-121>

<https://www.tandfonline.com/doi/full/10.1080/24751839.2024.2317509>

<https://link.springer.com/article/10.1186/s12874-022-01578-w>